

처음 보는 조선소에서도 도로, 야드, 공장을 구분한다

구조 유도 조선소 간 의미 분할: 경계·영역 제약은 학습에만 쓰고 배포 모형은 그대로

Structure-guided cross-site semantic segmentation of shipyard remote-sensing imagery

Chunrui Na, Qing Wang, Jingzheng Yao*, Youngrong Kim*

하얼빈공정대학 · 난양이공대학 · 하얼빈공정대학 엔타이연구원

Ocean Engineering 368 (2026) 128269 · doi:10.1016/j.oceaneng.2026.128269

그림: 논문 그림 1 (영상 Google, Airbus). * 교신저자.



1분 요약

1

과제

조선소 영상을 배경, 도로, 야드 개방 구역, 생산 건물로 나눈다. 다른 조선소에서는 배치와 외관이 달라 경계가 흐려지고 큰 영역 내부가 조각난다.

2

방법

SegFormer-B2에 학습 제약 두 가지: 레이블 형태학에서 만든 경계 제약, 학습 가능한 원형 8개의 영역 일관성 제약. 추론 때는 둘 다 제거.

3

결과

미학습 조선소 5곳 × 시드 3개: mIoU 0.6793 → **0.6907**, 경계 F1 0.7190 → 0.7393, 조각 비율 0.0775 → 0.0631. 10개 비교 모두 향상.

4

비용

배포 모형은 기준 모형과 동일: 매개변수 27.35 M, 92.1 GFLOPs. 학습만 조금 늘어남: 에폭당 32.20 → 34.18초.

경계는 전이를, 영역은 내부를: 서로 보완하며 배포 비용은 없다.

보고 순서 (클릭하면 이동)

1

배경과 어려움

조선소 의미 지도의 쓰임, 새 조선소가 어려운 이유

p. 4

2

데이터와 평가 절차

조선소 8곳, 패치 988개, 5곳을 차례로 제외

p. 6

3

방법

경계 제약과 영역 일관성 제약

p. 8

4

주요 결과

중첩, 클래스, 경계·조각, 조선소별, 긴 학습

p. 11

5

메커니즘과 공학적 가치

원형 학습, 배포 비용 없음, 도로 연결성

p. 16

6

정성 결과

5개 조선소 비교, 국소 개선과 남은 오류

p. 19


7

결론

기여와 박사 논문에서의 위치

p. 21

조선소 의미 지도: 영상을 디지털 트윈과 운송 계획의 공간 기반으로




어려움: 다른 조선소에서는 배치, 시설, 도로, 외관이 모두 바뀐다

1 장면 수준 분포 이동
건물 밀도, 도로 기하, 야드 질감, 전체 구성이 조선소마다 다르다


2 인접 기능 구역의 약한 경계
도로-야드, 건물 가장자리에서 오류가 몰린다

3 큰 영역 내부의 조각남
균일한 야드나 지붕이 작은 조각들로 예측된다

대상 조선소 영상은 학습이나 적응에 전혀 쓰지 않는다:
도메인 적응이 아닌 도메인 일반화.



데이터셋: 조선소 8곳, 패치 988개, 약 23.3 km², 대체로 균형 잡힌 네 클래스



■ 미학습 시험 조선소 (차레로) ■ 학습에만

네 클래스의 픽셀 비율



247 → 988

1024 × 1024 원본을 512 × 512 네 조각으로, 약 0.30 m/픽셀, 2025년 Google Earth Pro에서 추출

0.921 mIoU · 0.887 BF1

세 명이 독립 표시 후 검토·판정, 99개 품질 관리 부분집합 (10.02%)의 표시자 간 일치도


평가 절차: 5개 조선소를 차례로 제외하고, 검증 조선소도 두 가지로 배정

시험 조선소	검증 조선소	학습 / 검증 / 시험 패치
한화오션	삼성중공업 거제	516 / 148 / 324
현대삼호	한화오션	568 / 324 / 96
장쑤 뉴타임스	현대삼호	792 / 96 / 100
삼성중공업 거제	양쯔장 조선	628 / 212 / 148
양쯔장 조선	장쑤 뉴타임스	676 / 100 / 212


- 조선소 하나 제외 (LOSO): 표본이 충분한 5곳이 차례로 시험 조선소, 대상 조선소 영상은 학습·적응에 쓰지 않음
- 두 가지 검증 배정 A, B: 학습 전에 고정, 각각 5주기, 시험 조선소마다 A와 B의 검증 짝이 다르다
- 시드 3개 (3407, 5519, 7823) → 방법·배정마다 15회 실행, 검증 mIoU로 체크 포인트 선택
- 두 가지 학습 예산: 30에폭 통제 비교 (같은 백본의 절제), 120에폭 외부 방법 비교

표는 주 비교에 쓰는 배정 B: 폴드마다 시험 1곳, 검증 1곳, 학습 6곳.

아이디어: 경계 제약은 전이를, 영역 일관성 제약은 내부를



구조: 보조 분기 두 개는 학습에만 있고 추론 때 모두 제거



Joint training objective

$$\mathcal{L} = \mathcal{L}_{ce} + \lambda_{dice} \mathcal{L}_{dice} + \lambda_b \mathcal{L}_{boundary} + \lambda_r \mathcal{L}_{region}$$

$$\mathcal{L} = \mathcal{L}_{ce} + \lambda_{dice} \mathcal{L}_{dice} + \lambda_b \mathcal{L}_{boundary} + \lambda_r \mathcal{L}_{region} \quad \cdot \quad \lambda_{dice} = 1.0, \lambda_b = 0.5, \lambda_r = 0.1$$


세 분기가 융합 디코더 특징 F_{fuse} 를 공유: 분할 헤드 (CE + Dice), 경계 헤드 (BCE), 영역 일관성 분기 (KL). 배포 그래프는 SegFormer-B2 그대로.

두 제약의 구성: 추가 레이블 없이, 추론 변경 없이

경계 제약: 전이

$$B = \max_c \text{clip}(\text{Dilate}(M_c) - \text{Erode}(M_c), 0, 1) \quad (3 \times 3)$$

- 경계 목표는 레이블의 형태학적 기울기에서 바로 얻어 별도 경계 레이블이 없고, 이상적인 직선 전이는 약 2픽셀 (0.6 m) 띠가 된다
- 가벼운 경계 헤드 (3 × 3 합성곱 256 → 128, BN, ReLU, 1 × 1 합성곱), BCE 감독




영역 일관성 제약: 내부

$$\tilde{q}_i = \sum_r a_{i,r} \text{softmax}(z_r) \quad \cdot \quad \mathcal{L}_{\text{region}} = \text{KL}(p_i \parallel \tilde{q}_i)$$

- 학습 가능한 영역 원형 8개 (8 × 256), 픽셀 특징과 원형의 코사인 유사도 (온도 $\tau = 0.07$)로 소프트 배정 a
- 배정에 따라 영역 특징 집계 → 영역 분류 → 각 픽셀로 투영해 영역 수준 분포 $\tilde{q}$
- 픽셀 예측 p 를 $\tilde{q}$ 에 맞추고 (KL) 양쪽을 갱신해 한 영역 안의 예측이 조각나지 않게
- 대조: 원형을 무작위로 뽑아 고정 (fixed-random)해 원형 학습 가능성만 검증

주 비교: 결합 모형이 세 중첩 지표 모두 최고, 각 분기 단독도 향상




네 클래스 모두 최고, 차이가 가장 큰 것은 건물과 도로

방법	배경	건물	도로	야드	FG_MIOU	MIOU
U-Net	0.6242	0.7269	0.5516	0.5689	0.6158	0.6179
DeepLabV3+	0.6000	0.6885	0.5318	0.5509	0.5904	0.5928
D2LS	0.6514	0.7852	0.5854	0.6088	0.6598	0.6577
UrbanSSF-L	0.6358	0.7802	0.5562	0.5806	0.6390	0.6382
SegFormer-B2	0.6882	0.8020	0.6201	0.6069	0.6763	0.6793
B2 + 경계	0.6938	0.8108	0.6225	0.6037	0.6790	0.6827
B2 + 영역	0.6955	0.8105	0.6248	0.6068	0.6807	0.6844
B2 + 경계 + 영역 (고정 무작위)	0.6833	0.8141	0.6042	0.6100	0.6761	0.6779
B2 + 경계 + 영역 (제안)	0.6960	0.8237	0.6323	0.6108	0.6889	0.6907

2위 대비 차이: 건물 +0.0096, 도로 +0.0075, 야드 +0.0008, 배경 +0.0005. 색이 진할수록 열 안에서 높다.


출처: 논문 표 7 (배정 B 15회 실행, 9개 방법의 클래스별·전체 IoU).

구조 품질: 더 정확한 경계, 더 적은 조각, 더 적은 내부 오류, 두 분기의 상보성



■ SegFormer-B2
 ■ B2 + 경계
 ■ B2 + 영역
 ■ B2 + 경계 + 영역 (고정 무작위)
 ■ B2 + 경계 + 영역 (제안)

조각 비율과 내부 오류율 (낮을수록 좋음)



0.7190 → 0.7393

경계 F1 (1픽셀 허용), 2·3픽셀에서도 최고

-18.6%

소형 연결 요소 비율 (조각 비율) 0.0775 → 0.0631

-20.3%


내부 오류율 0.1480 → 0.1180, 야드 0.158 → 0.116

경계만은 경계 F1에, 영역만은 조각과 내부 오류에 더 도움이 되고, 결합 모형은 둘 다 얻는다.

조선소별: 모든 미학습 조선소, 두 검증 배정에서 향상이 모두 양수

SegFormer-B2 대비

고정 무작위 대비



10 / 10

조선소 × 검증 배정 비교, 세 지표 모두 양수


	조선소 수준 평균 Δ		95% 구간	양수 조선소	효과 크기 D_z
mIoU	+0.01175	[0.00730, 0.01621]		5/5	2.06
fg_mIoU	+0.01608	[0.01002, 0.02214]		5/5	2.01
mDice	+0.00795	[0.00474, 0.01115]		5/5	1.95

■ mIoU ■ fg_mIoU ■ mDice ● ● 배정 A ■ ■ 배정 B

출처: 논문 표 10-12. 점마다 한 시험 조선소의 한 배정에서 시드 3개 평균 향상. 조선소 수준 대응은 조선소마다 두 배정·세 시드를 평균해 5개 차이, 95% 구간은 3,125개 재표본 전부의 백분위 구간. $n = 5$ 가 모두 양수일 때 양측 정확 Wilcoxon $p = 0.0625$ 로, 5쌍이 가질 수 있는 최솟값이다.

긴 학습: 120에폭에서도 우위 유지, 다섯 조선소 모두 기준보다 높다

120에폭 30에폭



+0.0163 - +0.0540

다섯 조선소에서 SegFormer-B2 대비 fg_mIoU 향상: +0.0163~+0.0540

0.6942

120에폭: mIoU 0.6782 → 0.6942

0.7018

120에폭: fg_mIoU 0.6655 → 0.7018


0.8103

120에폭: mDice 0.8021 → 0.8103

■ U-Net ■ DeepLabV3+ ■ D2LS ■ UrbanSSF-L ■ SegFormer-B2 ■ B2 + 경계 + 영역 (제안)

출처: 논문 표 15·17·18, §5.7. 120에폭에서는 방법마다 자체 기준 학습률과 코사인 스케줄, 학습률 0.5×1×2× 각각에서 결합 모형이 세 지표 모두 1위이고, 격자 전체 최저 평균이 모든 비교 대상의 최고 평균보다 높다.

원형은 실제로 학습한다: 학습 가능한 원형이 고정 무작위를 앞서고 주변 설정도 견고



+0.0091 mIoU

고정 무작위 원형 대비 조선포 수준 평균 향상, 95% 구간 [0.0062, 0.0113], 5/5곳 양수

0.512 → 0.802

위치별 최대 배정 확률: 학습한 원형은 더 집중적으로 배정 (정규화 엔트로피 0.641 → 0.312)

7.56-7.95 / 8

유효 원형 수: 전체적으로 8개 모두 사용, 붕괴 없음

왼쪽의 단일 요인 설정 11개 모두 SegFormer-B2와 고정 무작위 대조보다 높다.

배포 비용 없음: 추론 모형은 SegFormer-B2와 동일

27.35 M

배포 매개변수 (기준과 동일)

92.1 G

FLOPs (기준과 동일)


31.10 ms

영상당 추론 지연, 기준 31.14 ms


+6.1%

에폭당 학습 32.20 → 34.18초, 보조 매개변수 364,165개는 학습에만


학습 (초 / 에폭)



추론 지연 (ms / 영상)



도로망 추출로: 국소 연결성 개선, 장거리 도달은 여전히 위상 보정 필요



■ B2 + 경계 ■ B2 + 영역 ■ B2 + 경계 + 영역 (고정 무작위) ■ B2 + 경계 + 영역 (제안)

6.57% → 4.88%

국소 경로 단절 비율 (한 연결 도로 안 4.8–19.2 m 떨어진 기종점 쌍)


0.0733 → 0.0586

잘못된 연결: 떨어진 도로가 잘못 이어진 비율

0.2704


장거리 끝점 도달률 (≥ 38.4 m): 여전히 낮아 운송 계획 전에 위상 보정과 GIS 벡터화가 필요

미학습 조선소 5곳의 정성 비교: 더 뚜렷한 전이, 더 적은 내부 조각




국소 개선과 남은 오류

개선: (a) 도로-야드 경계 (b) 건물 경계 (c) 야드 내부



남은 오류: (a) 도로-야드 혼동 (b) 그림자·가림 (c) 가는 연결 끊김



결론: 상보적 학습 제약으로 조선소 간 지도가 더 정확하고 깔끔해지며 배포 비용은 없다

1

조선소 간 평가 절차

미학습 조선소 5곳, 검증 배정 2가지, 시드 3개

2

학습 제약 두 가지

형태학 경계 + 원형 영역 일관성, 추론 때 제거

3

통제 절제

경계, 영역, 원형 학습의 기여를 분리

4

상보적 구조 개선

경계·내부 오류 모두 감소, 배포 그래프 불변

박사 논문에서의 위치

다수 조선소 배치의 의미 기반 지도를 제공해 6장의 배치 추출을 빠르게 할 수 있으며, 도로 위상은 여전히 중심선으로 추적하고 분할 결과는 보조와 인용으로 쓴다.

다음 단계

지역·센서·계절을 넘는 외부 검증, 위상 보정한 지도가 경로 계획을 개선하는지.

[박사 논문 보고 →](#)[코드 →](#)

경계는 전이를, 영역은 내부를: 서로 보완하며 배포 비용은 없다.

감사합니다.

참고문헌 (1/2)

1. Na, C., Wang, Q., Yao, J., Kim, Y. (2026). Structure-guided cross-site semantic segmentation of shipyard remote-sensing imagery. *Ocean Engineering* 368, 128269. doi:10.1016/j.oceaneng.2026.128269
2. Bertasius, G., Shi, J., Torresani, L. (2016). Semantic segmentation with boundary neural fields. *Proc. CVPR*, 3602–3610.
3. Borse, S., Wang, Y., Zhang, Y., Porikli, F. (2021). InverseForm: a loss function for structured boundary-aware segmentation. *Proc. CVPR*, 5901–5911.
4. Chen, L.C., Zhu, Y., Papandreou, G., Schroff, F., Adam, H. (2018). Encoder-decoder with atrous separable convolution for semantic image segmentation. *Proc. ECCV*, 833–851. doi:10.1007/978-3-030-01234-2_49
5. Efron, B., Tibshirani, R. (1986). Bootstrap methods for standard errors, confidence intervals, and other measures of statistical accuracy. *Statistical Science* 1(1), 54–75. doi:10.1214/ss/1177013815
6. Han, Y.S., Lee, K., Nam, B., Kim, Y.O., Kim, Y., Yeo, H.B. (2024). Assessment of ship-block stacking status based on images obtained from drone and GIS data. *Int. J. Naval Architecture and Ocean Engineering* 16, 100583. doi:10.1016/j.ijnaoe.2024.100583
7. Hill, M.O. (1973). Diversity and evenness: a unifying notation and its consequences. *Ecology* 54(2), 427–432. doi:10.2307/1934352
8. Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian J. Statistics* 6(2), 65–70.
9. Milletari, F., Navab, N., Ahmadi, S.-A. (2016). V-Net: fully convolutional neural networks for volumetric medical image segmentation. *Proc. 3DV*, 565–571. doi:10.1109/3dv.2016.79
10. Qin, W., Song, Y., Zhu, H., Yu, X., Tu, Y. (2023). A novel shipyard production state monitoring method based on satellite remote sensing images. *Remote Sensing* 15(20), 4958. doi:10.3390/rs15204958
11. Ronneberger, O., Fischer, P., Brox, T. (2015). U-Net: convolutional networks for biomedical image segmentation. *Proc. MICCAI*, 234–241. doi:10.1007/978-3-319-24574-4_28

참고문헌 (2/2)

12. Wang, C., Wang, K., Tao, J., Zhou, Y. (2020). Research on real-time optimal path planning model and algorithm for ship block transportation in shipyard. *J. Marine Science and Engineering* 8(12), 991. doi:10.3390/jmse8120991
13. Wang, J., Zheng, Z., Ma, A., Lu, X., Zhong, Y. (2021). LoveDA: a remote sensing land-cover dataset for domain adaptive semantic segmentation. *NeurIPS Datasets and Benchmarks*.
14. Wang, N., Yin, J., Khan, R.U. (2024). Risk coupling assessment of vehicle scheduling for shipyard in a complicated road environment. *J. Marine Science and Engineering* 12(4), 685. doi:10.3390/jmse12040685
15. Wang, Z., Yi, J., Chen, A., Chen, L., Lin, H., Xu, K. (2025). Accurate semantic segmentation of very high-resolution remote sensing images considering feature state sequences (UrbanSSF). *ISPRS J. Photogrammetry and Remote Sensing* 220, 824–840. doi:10.1016/j.isprsjprs.2025.01.017
16. Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin* 1(6), 80–83. doi:10.2307/3001968
17. Xie, E., Wang, W., Yu, Z., Anandkumar, A., Alvarez, J.M., Luo, P. (2021). SegFormer: simple and efficient design for semantic segmentation with transformers. *NeurIPS* 34, 12077–12090.
18. Yuan, Y., Chen, X., Wang, J. (2020). Object-contextual representations for semantic segmentation. *Proc. ECCV*, 173–190. doi:10.1007/978-3-030-58539-6_11
19. Zhang, T.Y., Suen, C.Y. (1984). A fast parallel algorithm for thinning digital patterns. *Communications of the ACM* 27(3), 236–239. doi:10.1145/357994.358023
20. Zou, X., Li, Y., Zhang, S., Li, K., Wang, S., Tao, P., Xing, J., Lang, C. (2025). Dynamic dictionary learning for remote sensing image segmentation (D2LS). *Proc. ICCV*, 22457–22466.