


没见过的船厂， 也要分得清道路、 堆场和厂房

结构引导的跨船厂遥感影像语义分割：边界约束与区域一致性约束只在训练时使用，部署模型不变

Structure-guided cross-site semantic segmentation of shipyard remote-sensing imagery

Chunrui Na, Qing Wang, Jingzheng Yao*, Youngrong Kim*
哈尔滨工程大学 · 南洋理工大学 · 哈尔滨工程大学烟台研究院
Ocean Engineering 368 (2026) 128269 · doi:10.1016/j.oceaneng.2026.128269

图：论文图 1（影像来源 Google、Airbus）。* 通讯作者。



0.6793 → 0.6907
mIoU, 5 座留出船厂

10 / 10
船厂 × 验证分配全部提升

27.35 M
部署参数不变



一分钟看完这篇论文

1

问题

把船厂影像分成背景、道路、堆场开阔区、生产厂房四类。换一座船厂，布局 and 外观都变，类别交界变模糊、大区域内部变破碎。

2

做法

在 SegFormer-B2 上加两路训练约束：从标签形态学导出的边界约束，和 8 个可学习原型的区域一致性约束。推理时两路都去掉。

3

结果

5 座留出船厂 × 3 个种子：
mIoU 0.6793 → **0.6907**，
边界 F1 0.7190 →
0.7393，碎片率 0.0775 →
0.0631。两种验证分配下
10 组比较全部提升。

4

代价


部署模型与基线完全相同：
27.35 M 参数、92.1
GFLOPs。只多一点训练时间：每轮 32.20 →
34.18 s。

边界管交界, 区域管内部: 两者互补, 部署零代价。

汇报顺序(点击跳转)

1	背景与难点 船厂语义地图有什么用；换一座船厂难在哪里	p. 4	2	数据与评测协议 8 座船厂、988 个影像块；五座轮流留出	p. 6
3	方法 边界约束与区域一致性约束	p. 8	4	主要结果 重叠、类别、边界与碎片、逐厂、长训练	p. 11
5	机理与工程价值 原型在学；部署零代价；路网连通	p. 16	6	定性结果 五座船厂的对比；局部改进与剩余错误	p. 19
7	结论 贡献与在博士论文中的位置	p. 21			

船厂语义地图:把影像变成数字孪生和运输规划能用的空间底图



来源: 论文图 1 (影像来源 Google、Airbus) 与第 3.2 节类别定义。语义地图可作为路网提取、功能分区、设施定位与空间索引的输入; 这些下游模块不在本文范围内。

难点:换一座船厂,布局、设施、道路和外观都变了

1

场景级分布偏移

建筑密度、道路几何、堆场纹理和整体组织因厂而异

2

相邻功能区的交界模糊


道路与堆场、厂房边缘最容易错

3


大区域内部破碎

均匀的堆场或屋顶被预测成零碎的小块

目标船厂的影像不参与任何训练或适应:这是域泛化, 不是域适应。



数据集: 8 座船厂、988 个影像块、约 23.3 km², 四类像素大致均衡



■ 留出测试厂 (轮流) ■ 只参与训练

四类像素占比



247 → 988

1024 × 1024 原图切成四块 512 × 512; 约 0.30 m/像素; 2025 年由 Google Earth Pro 导出

0.921 mIoU · 0.887 BF1

三人独立标注、复核与仲裁; 质控子集 99 块 (10.02%) 上标注者两两一致性


评测协议:五座船厂轮流留出测试, 验证厂也换两种分配

测试厂	验证厂	训练 / 验证 / 测试 块数
韩华海洋（巨济）	三星重工巨济	516 / 148 / 324
现代三湖	韩华海洋（巨济）	568 / 324 / 96
江苏新时代	现代三湖	792 / 96 / 100
三星重工巨济	扬子江船业	628 / 212 / 148
扬子江船业	江苏新时代	676 / 100 / 212

- **留一船厂（LOSO）**：五座样本充足的船厂轮流作测试厂；目标船厂的影像不参与训练或适应
- **两种验证分配 A、B**：训练前写定，各成一个五元循环；每座测试厂在 A、B 中的验证伙伴不同
- **3 个随机种子**（3407、5519、7823）→ 每种方法、每种分配 15 次运行；按验证集 mIoU 选模型
- **两个训练预算**：30 轮的受控比较（同骨干的消融），120 轮的外部方法比较


上表为主比较所用的分配 B。每折一座测试厂、一座验证厂，其余六座训练。

思路:边界约束管类别交界, 区域一致性约束管大区域内部



来源: 论文图 4。左: 未见船厂的结构性问题; 中: 互补的两路结构监督 (边界: 边缘检测头 + BCE; 区域: 原型头 + KL 一致性); 右: 期望的地图改进。

结构：两路辅助分支只在训练时存在，推理时整体移除



Joint training objective

$$\mathcal{L} = \mathcal{L}_{ce} + \lambda_{dice} \mathcal{L}_{dice} + \lambda_b \mathcal{L}_{boundary} + \lambda_r \mathcal{L}_{region}$$

$$\mathcal{L} = \mathcal{L}_{ce} + \lambda_{dice} \mathcal{L}_{dice} + \lambda_b \mathcal{L}_{boundary} + \lambda_r \mathcal{L}_{region} \quad \cdot \quad \lambda_{dice} = 1.0, \lambda_b = 0.5, \lambda_r = 0.1$$


三路共享融合解码特征 F_{fuse} ：分割头（CE + Dice）、边界头（BCE）、区域一致性分支（KL）。部署图仍是 SegFormer-B2。

两个约束怎样构造:不需要额外标注,也不改变推理

边界约束:管交界

$$B = \max_c \text{clip}(\text{Dilate}(M_c) - \text{Erode}(M_c), 0, 1) \quad (3 \times 3)$$

- 由语义标签的形态学梯度直接得到边界目标, 不需要专门的边界标注; 理想直线交界形成约 2 像素 (0.6 m) 的带
- 轻量边界头 (3 × 3 卷积 256→128、BN、ReLU、1 × 1 卷积), BCE 监督




区域一致性约束:管内部

$$\tilde{q}_i = \sum_r a_{i,r} \text{softmax}(z_r) \quad \cdot \quad \mathcal{L}_{\text{region}} = \text{KL}(p_i \parallel \tilde{q}_i)$$

- 8 个可学习区域原型** (8 × 256); 像素特征与原型的余弦相似度 (温度 $\tau = 0.07$) 给出软分配 a
- 按分配聚合区域特征 → 区域分类 → 投回每个像素, 得到区域级语义分布 $\tilde{q}$
- 让像素预测 p 与区域分布 $\tilde{q}$ 一致 (KL), 两边都更新: 同一区域内的预测不再零碎
- 对照:** 原型随机初始化后冻结 (固定随机), 只检验“原型可学习”这一项

主比较:联合模型三项重叠指标都最高, 两路单独也各有提升



来源: 论文表 5 (分配 B, 30 轮, 每种方法 15 次运行, 均值 ± 样本标准差; 标准差含船厂与种子两种变异) 与表 6 (分配 A)。外部方法与受控变体共用折、种子、增强与选模规则。


四个类别都最高, 提升最大的是厂房和道路

方法	背景	厂房	道路	堆场	FG_MIOU	MIOU
U-Net	0.6242	0.7269	0.5516	0.5689	0.6158	0.6179
DeepLabV3+	0.6000	0.6885	0.5318	0.5509	0.5904	0.5928
D2LS	0.6514	0.7852	0.5854	0.6088	0.6598	0.6577
UrbanSSF-L	0.6358	0.7802	0.5562	0.5806	0.6390	0.6382
SegFormer-B2	0.6882	0.8020	0.6201	0.6069	0.6763	0.6793
B2 + 边界	0.6938	0.8108	0.6225	0.6037	0.6790	0.6827
B2 + 区域	0.6955	0.8105	0.6248	0.6068	0.6807	0.6844
B2 + 边界 + 区域 (固定随机原型)	0.6833	0.8141	0.6042	0.6100	0.6761	0.6779
B2 + 边界 + 区域 (本文)	0.6960	0.8237	0.6323	0.6108	0.6889	0.6907

相对第二名的领先：厂房 +0.0096、道路 +0.0075、堆场 +0.0008、背景 +0.0005。颜色越深表示该列中越高。


来源：论文表 7（分配 B 的 15 次运行，九种方法的类别 IoU 与汇总 IoU）。

结构质量:边界更准、碎片更少、区域内部错误更少, 两路互补




碎片率与内部错误率 (越低越好)

碎片率



内部错误率



0.7190 → 0.7393

边界 F1 (1 像素容差) ; 2、3 像素容差下同样最高

-18.6%

小连通块占比 (碎片率) 0.0775 → 0.0631

-20.3%


区域内部错误率 0.1480 → 0.1180; 堆场 0.158 → 0.116

只加边界对边界 F1 帮助更大, 只加区域对碎片与内部错误帮助更大: 联合模型两者兼得。

■ SegFormer-B2
 ■ B2 + 边界
 ■ B2 + 区域
 ■ B2 + 边界 + 区域 (固定随机原型)
 ■ B2 + 边界 + 区域 (本文)

来源: 论文表 8、表 9 (分配 B)。BF1 只比较交界位置; 碎片率 = 面积小于 32 像素 (2.88 m²) 的前景连通块像素占比; 内部错误率在 5 × 5 腐蚀后的类别内部计算。

逐厂看：每座留出船厂、两种验证分配, 提升全部为正



10 / 10

船厂 × 验证分配的比较，三项指标全部为正


	船厂级平均 Δ	95% 区间	为正的船厂	效应量 D_z
mIoU	+0.01175	[0.00730, 0.01621]	5/5	2.06
fg_mIoU	+0.01608	[0.01002, 0.02214]	5/5	2.01
mDice	+0.00795	[0.00474, 0.01115]	5/5	1.95

来源：论文表 10–12。每个点是一座测试船厂在一种分配下三个种子的均值增益。船厂级配对：每厂先平均两种分配与三个种子，得 5 个配对差；95% 区间为枚举全部 3125 次有放回重抽样的百分位区间。n = 5 时，全部为正的双侧精确 Wilcoxon 检验 $p = 0.0625$ ，这也是 5 对所能取到的最小值。

更长训练:120 轮下优势保持, 五座船厂都高于基线

120 轮

30 轮

**+0.0163 – +0.0540**

五座船厂相对 SegFormer-B2 的 fg_mIoU 增益: +0.0163 到 +0.0540

0.6942

120 轮: mIoU 0.6782 → 0.6942

0.7018

120 轮: fg_mIoU 0.6655 → 0.7018

0.8103


120 轮: mDice 0.8021 → 0.8103

U-Net DeepLabV3+ D2LS UrbanSSF-L SegFormer-B2

B2 + 边界 + 区域 (本文)

来源: 论文表 15、17、18 与第 5.7 节。120 轮各方法采用各自的参考学习率与余弦调度; 学习率在 0.5×、1×、2× 三档下, 联合模型在每一档三项指标都排第一, 且它在全网格中的最低均值高于任一对手的最高均值。

原型确实在学:可学习原型胜过固定随机原型, 参数在附近都稳健



+0.0091 mIoU

对固定随机原型的船厂级平均增益, 95% 区间 [0.0062, 0.0113], 5/5 座船厂为正

0.512 → 0.802

每个位置最大分配概率: 学到的原型分配更集中 (归一化熵 0.641 → 0.312)

7.56-7.95 / 8

有效原型数: 总体上 8 个原型都被使用, 没有坍缩

左图 11 种单因素配置全部高于 SegFormer-B2 与固定随机原型。

部署零代价:推理时的模型与 SegFormer-B2 完全相同

27.35 M

部署参数（与基线相同）

92.1 G

FLOPs（与基线相同）


31.10 ms

单张推理延迟；基线 31.14 ms


+6.1%

训练每轮 32.20 → 34.18 s；辅助参数 364,165 个只在训练中


训练 (s / 轮)



推理延迟 (ms / 张)



面向路网提取：局部连通更好，长距离可达仍需拓扑修复



■ B2 + 边界 ■ B2 + 区域 ■ B2 + 边界 + 区域 (固定随机原型) ■ B2 + 边界 + 区域 (本文)

6.57% → 4.88%

局部路径断开的比例（同一连通块内 4.8–19.2 m 的起讫对）


0.0733 → 0.0586

错误连通：本不相连的道路被连起来的比例

0.2704

长距离端点可达率 (≥ 38.4 m)：仍然偏低，用于运输规划前需要拓扑修复与 GIS 矢量化


五座留出船厂上的定性对比:交界更清楚, 内部碎片更少




来源: 论文图 10 (30 轮模型; 影像来源 Google、Airbus)。列: 影像、真值、D2LS、UrbanSSF-L、SegFormer-B2、+边界、+区域、+边界+区域 (本文)。

局部改进与仍然存在的错误

改进：(a) 道路-堆场交界 (b) 厂房边界 (c) 堆场内部



剩余错误：(a) 道路与堆场混淆 (b) 阴影或遮挡 (c) 细长连接断开



结论：两路训练约束互补，跨船厂更准、更干净，部署不加成本

1

跨船厂评测协议

五座留出测试厂、两种验证分配、三个种子

2

两路训练约束

形态学边界 + 原型区域一致性，推理时移除

3

受控消融

分清边界、区域与原型可学习各自的贡献

4

互补的结构改进

交界与内部错误同时减少，部署图不变

在博士论文中的位置

为多船厂布局提供语义底图，可加快第 6 章多船厂布局的提取；路网拓扑仍按中心线描图，分割结果作为辅助与引用。

下一步

跨地区、跨传感器、跨季节的外部检验；拓扑修复后的语义图能否改进路径规划。

[博士论文汇报 →](#)[代码 →](#)

边界管交界，区域管内部：两者互补，部署零代价。

谢谢，请老师指正。

参考文献(1/2)

1. Na, C., Wang, Q., Yao, J., Kim, Y. (2026). Structure-guided cross-site semantic segmentation of shipyard remote-sensing imagery. *Ocean Engineering* 368, 128269. doi:10.1016/j.oceaneng.2026.128269
2. Bertasius, G., Shi, J., Torresani, L. (2016). Semantic segmentation with boundary neural fields. *Proc. CVPR*, 3602–3610.
3. Borse, S., Wang, Y., Zhang, Y., Porikli, F. (2021). InverseForm: a loss function for structured boundary-aware segmentation. *Proc. CVPR*, 5901–5911.
4. Chen, L.C., Zhu, Y., Papandreou, G., Schroff, F., Adam, H. (2018). Encoder-decoder with atrous separable convolution for semantic image segmentation. *Proc. ECCV*, 833–851. doi:10.1007/978-3-030-01234-2_49
5. Efron, B., Tibshirani, R. (1986). Bootstrap methods for standard errors, confidence intervals, and other measures of statistical accuracy. *Statistical Science* 1(1), 54–75. doi:10.1214/ss/1177013815
6. Han, Y.S., Lee, K., Nam, B., Kim, Y.O., Kim, Y., Yeo, H.B. (2024). Assessment of ship-block stacking status based on images obtained from drone and GIS data. *Int. J. Naval Architecture and Ocean Engineering* 16, 100583. doi:10.1016/j.ijnaoe.2024.100583
7. Hill, M.O. (1973). Diversity and evenness: a unifying notation and its consequences. *Ecology* 54(2), 427–432. doi:10.2307/1934352
8. Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian J. Statistics* 6(2), 65–70.
9. Milletari, F., Navab, N., Ahmadi, S.-A. (2016). V-Net: fully convolutional neural networks for volumetric medical image segmentation. *Proc. 3DV*, 565–571. doi:10.1109/3dv.2016.79
10. Qin, W., Song, Y., Zhu, H., Yu, X., Tu, Y. (2023). A novel shipyard production state monitoring method based on satellite remote sensing images. *Remote Sensing* 15(20), 4958. doi:10.3390/rs15204958

参考文献(2/2)

11. Ronneberger, O., Fischer, P., Brox, T. (2015). U-Net: convolutional networks for biomedical image segmentation. *Proc. MICCAI*, 234–241. doi:10.1007/978-3-319-24574-4_28
12. Wang, C., Wang, K., Tao, J., Zhou, Y. (2020). Research on real-time optimal path planning model and algorithm for ship block transportation in shipyard. *J. Marine Science and Engineering* 8(12), 991. doi:10.3390/jmse8120991
13. Wang, J., Zheng, Z., Ma, A., Lu, X., Zhong, Y. (2021). LoveDA: a remote sensing land-cover dataset for domain adaptive semantic segmentation. *NeurIPS Datasets and Benchmarks*.
14. Wang, N., Yin, J., Khan, R.U. (2024). Risk coupling assessment of vehicle scheduling for shipyard in a complicated road environment. *J. Marine Science and Engineering* 12(4), 685. doi:10.3390/jmse12040685
15. Wang, Z., Yi, J., Chen, A., Chen, L., Lin, H., Xu, K. (2025). Accurate semantic segmentation of very high-resolution remote sensing images considering feature state sequences (UrbanSSF). *ISPRS J. Photogrammetry and Remote Sensing* 220, 824–840. doi:10.1016/j.isprsjprs.2025.01.017
16. Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin* 1(6), 80–83. doi:10.2307/3001968
17. Xie, E., Wang, W., Yu, Z., Anandkumar, A., Alvarez, J.M., Luo, P. (2021). SegFormer: simple and efficient design for semantic segmentation with transformers. *NeurIPS* 34, 12077–12090.
18. Yuan, Y., Chen, X., Wang, J. (2020). Object-contextual representations for semantic segmentation. *Proc. ECCV*, 173–190. doi:10.1007/978-3-030-58539-6_11
19. Zhang, T.Y., Suen, C.Y. (1984). A fast parallel algorithm for thinning digital patterns. *Communications of the ACM* 27(3), 236–239. doi:10.1145/357994.358023
20. Zou, X., Li, Y., Zhang, S., Li, K., Wang, S., Tao, P., Xing, J., Lang, C. (2025). Dynamic dictionary learning for remote sensing image segmentation (D2LS). *Proc. ICCV*, 22457–22466.